



Catálogo de Fontes de Dados

Mapeamento consolidado das fontes que abastecem o data lake do Ministério da Cultura: sistema, unidade proprietária, forma de acesso, autenticação, periodicidade, destino e situação da integração.

Universidade de Brasília

Lab Livre · Faculdade do Gama, UnB

Ministério da Cultura

Gov Hub BR

Projeto de Pesquisa

Plataforma de Dados do Ministério da Cultura · Gov Hub BR

Meta 01 · Produto 2

Diagnóstico técnico e institucional das fontes de dados.

Documento

Catálogo de Fontes de Dados



Índice

01	Introdução	4
02	Metodologia e arquitetura de ingestão	6
	Método de levantamento	6
	A arquitetura comum de ingestão	6
03	Visão consolidada das fontes	9
04	Fichas por fonte de dados	12
	01 · SALIC — Sistema de Apoio às Leis de Incentivo à Cultura	12
	02 · TransfereGov — módulo Fundo a Fundo	14
	03 · Relatórios de Gestão PNAB/LPG — planilhas dos entes federados	15
	04 · BB Gestão Ágil — extrato bancário via BSC/SERPRO	16
	05 · IBGE — Censo 2022 · Favelas e Comunidades Urbanas (FCU)	17
	06 · Cadastros do Sistema Nacional de Cultura (SNC)	18
05	Manutenção do catálogo	19





O Gov Hub BR é a iniciativa que aproxima dados de No novo Plano Nacional de Cultura (2025–2035), sistemas estruturantes do Governo Federal da gestão enviado ao Congresso Nacional em novembro de pública baseada em evidências. No Ministério da Cul- 2025, este artefato serve diretamente a dois eixos. Ao tura, o laboratório Lab Livre (UnB) mantém o pipeline Eixo 1 — Gestão e Participação Social, porque data-application-minc , que ingere dados de siste- consolidar o Sistema Nacional de Cultura com finan- mas de governo, os transforma em um data warehou- ciamento descentralizado e transparência total exige se Postgres e serve o acompanhamento das metas saber, fonte a fonte, como a informação da execução da Política Nacional Aldir Blanc (PNAB) e da Lei Paulo chega ao Ministério — é exatamente o percurso Gustavo (LPG). TransfereGov → entes federados → relatórios de gestão mapeado aqui. E ao Eixo 8 — Cultura Digital Este documento é o primeiro dos quatro artefatos da e Direitos Digitais, porque um Estado que formula Fase 1 — Fundamentos de Dados: o Catálogo de política com base em dados deve documentar de Fontes de Dados. A sua função é responder, com onde cada informação vem, por qual via ela é aces- precisão auditável, de onde vem cada dado que o sada e sob qual guarda ela vive — compromisso que Ministério usa para monitorar suas políticas de fo- este catálogo materializa fonte a fonte. mento — qual sistema, de quem é a custódia, como se acessa, com que credencial, em que ritmo e em As transversalidades do novo PNC — em especial in- que ponto do data lake ele pousa. terseccionalidade e territorialidade — atravessam o catálogo na prática: são as fontes aqui descritas A ausência desse mapa tem custo concreto: fontes (perfil autodeclarado de contemplados, crosswalk ter- duplicadas convivem sem aviso (o cadastro de pro- ritorial do IBGE) que permitem medir cotas raciais, de ponentes do SALIC existe hoje em duas gerações de pessoas com deficiência e de territórios vulnerabiliza- carga), schemas legados permanecem sem dono e dos. decisões de acesso ficam implícitas no código. O ca- tálogo torna essas escolhas visíveis e governáveis.

(a) a estrutura YAML versionada (docs/fase1-fundamentos/catalogo_fontes_dados.yaml), fonte de ver- dade legível por máquina; (b) a planilha (catalogo_fontes_dados.xlsx) gerada dela, para circulação em gestão; (c) este relatório diagramado, com uma ficha por fonte. As fontes obrigatórias do escopo — SA- LIC, PNAB, TransfereGov, MAPAS e cadastros do SNC — estão todas cobertas, junto das demais fontes reais do pipeline.



Como o mapeamento foi levantado e o caminho comum que toda fonte percorre até o lake.





Método de levantamento

Cada linha deste catálogo foi extraída da leitura direta do código do repositório — as rotinas de ingestão em `dags/data_ingest/`, os clientes de acesso em `plugins/`, os auxiliares de conexão e a declaração de fontes do projeto de transformação em `dbt/minc/models/sources.yml` — e conferida contra a documentação automatizada do SALIC publicada em `dbt/minc/docs/salic/`. Nada aqui é descrição de intenção: é o comportamento efetivo do pipeline.

Dois campos merecem nota metodológica. A **periodicidade** de boa parte das rotinas não está no código: vive numa variável do orquestrador, com execução diária como padrão — o catálogo registra essa condição em vez de fingir um agendamento fixo. A **autenticação** nunca expõe segredo: registra-se o mecanismo e o nome da variável de ambiente ou da conexão do orquestrador onde a credencial vive.

A fonte prevista dos cadastros do Sistema Nacional de Cultura entra no catálogo com status próprio, e com as decisões de acesso ainda em aberto.

A arquitetura comum de ingestão

Toda fonte ativa percorre o mesmo caminho: uma DAG do Airflow extrai da origem e grava no Postgres via `ClientPostgresDB`, que cria schema e tabela automaticamente, faz upsert por chave natural e tolera evolução de schema da origem. Não há transformação em Python — o dado pousa bruto (toda coluna nasce TEXT) e o tratamento é responsabilidade do dbt, executado pela DAG `minc_cosmos_dag` à 01:00.

Arquitetura Lógica — Origem, Ingestão e Armazenamento

Do sistema de origem ao dado bruto: fontes, DAGs do Airflow, PostgreSQL e MinIO




Figura 1. Arquitetura de ingestão e destino das fontes no data lake: do sistema de origem ao dado bruto. Cada rotina do orquestrador responde por um ponto de acesso de origem, com periodicidade própria. Em âmbar, os pontos pendentes. A coluna de ingestão detalha as dez rotinas do núcleo do monitoramento; as cinco incorporadas depois — as duas do plano de ação, a série do Banco Central, os agregados do IBGE e a segunda rotina do SALIC — ainda não estão representadas no desenho. Elaborado a partir da leitura do código do repositório.



Não existe dependência declarada entre as DAGs de ingestão e a execução do dbt: minc_cosmos_dag roda em horário fixo (01:00), ingestões em horários próprios. Há uma janela de corrida possível entre "dados ainda sendo ingeridos" e "dbt já transformando". O Catálogo de Metadados (Documento 4) registra esse risco como regra de qualidade a monitorar.

Todas as fontes numa página: acesso, ritmo, classificação e status.



Visão consolidada das fontes



A tabela reúne todas as fontes mapeadas, com forma de acesso, autenticação, periodicidade, destino no data lake e situação da integração.


Fonte	Forma de acesso	Autenticação	Periodicidade	Destino	Situação
SALIC	Conexão direta ao SQL Server, leitura por tabela em blocos de 50 mil linhas	Credencial de banco em conexão do orquestrador	Diária, com recarga completa por tabela	bronze	Ativa
TransfereGov	API REST pública paginada, mais API de anexos; onze programas filtrados	Nenhuma — interface pública	Diária por padrão, definida em configuração	transferegov	Ativa
Relatórios de Gestão PNAB e LPG	Download dos anexos para o object storage e leitura das planilhas por aba e modelo	Nenhuma na origem; credencial do object storage	Encadeada às rotinas anteriores	relatorio_gestao	Ativa
BB Gestão Ágil	API assíncrona por combinação de ente e período mensal, com controle idempotente	Token por esquema proprietário, com renovação	Diária por padrão, em janelas mensais	bbagil	Ativa em parte
IBGE — Censo 2022	Arquivo CSV pré-processado, disponibilizado localmente	Nenhuma — arquivo local	Manual: dado censitário estático	transferegov	Ativa
Cadastros do Sistema Nacional de Cultura	A definir entre interface, exportação periódica ou dump	A definir	A definir	a propor	Prevista

Fontes mapeadas, com forma de acesso, autenticação, periodicidade, destino no data lake e situação da integração.



A leitura da coluna de situação resume o estágio do data lake: o núcleo do monitoramento do fomento descentralizado e a réplica do SALIC encontram-se ativos e com carga diária; e a fonte dos cadastros do Sistema Nacional de Cultura permanece prevista.



**01 · SALIC — Sistema de Apoio às Leis de Incentivo à Cultura**

Campo	Conteúdo
Sistema de origem	SALIC (SQL Server, múltiplos bancos)
Unidade proprietária	Ministério da Cultura — Secretaria de Fomento e Incentivo à Cultura (SEFIC), gestora da Lei Rouanet
Políticas relacionadas	Lei Rouanet, leis de incentivo correlatas
Forma de acesso	Conexão SQL Server direta (MsSqlHook/pymssql), SELECT * por tabela com streaming em chunks de 50.000 linhas
Autenticação	credencial de banco na Airflow Connection · credencial: Connection `mssql_salic_<servidor>` (ex.: mssql_salic_agentes)
Periodicidade	@daily (00:00) — full refresh por tabela (DROP+CREATE)
DAGs	salic_ingestion
Configuração runtime	Airflow Variable `salic_data` (JSON): servidores, bancos, tabelas incluídas/ excluídas, chunk_size. Descoberta automática de tabelas via INFORMATION_SCHEMA quando a lista vem vazia.
Destino no data lake	schema bronze padrão <banco_origem>__<tabela> (ex.: sac__captacao) sac — 431 tabelas (núcleo — projetos, captação, pareceres, prestação de contas); tabelas — 67 tabelas (apoio — pessoas, logradouros, eventos); agentes — 57 tabelas (cadastro de agentes/proponentes); controledeacesso — 5 tabelas (usuários e permissões); bdcorporativo — 1 tabela (metadado técnico do SQL Server) Log de execução: control.salic_ingestion_log
Volumetria	561 tabelas · 5.064 colunas · maior tabela sac__intranet ≈ 5,28 mi linhas
Status da integração	Ativa
Consumo no dbt	Declarada como 5 sources dbt (salic_bronze/sources_*.yml, com meta OpenMetadata e 858 testes gerados); sem domínio analítico próprio, mas já consumida por modelos silver e gold do domínio de agentes, que dela extraem os eventos de captação da Lei Rouanet. Documentação existente: Catálogo e Dicionário de Dados do SALIC (DOCX/HTML/PDF, 561 tabelas, 5.064 colunas) em dbt/minc/docs/salic/, gerados pelo pipeline automatizado scripts/salic_docs/ (9 etapas). A cobertura é desigual: as 561 tabelas estão descritas, mas apenas 638 das 5.064 colunas (12,6%) têm definição de negócio herdada do dicionário original do sistema; as demais registram explicitamente a ausência dessa definição na origem.



02 · TransfereGov — módulo Fundo a Fundo

Campo	Conteúdo
Sistema de origem	Plataforma TransfereGov (Governo Federal)
Unidade proprietária	Ministério da Gestão e da Inovação em Serviços Públicos (plataforma); dados dos programas sob gestão do Ministério da Cultura
Políticas relacionadas	PNAB, LPG, demais programas fundo a fundo do MinC
Forma de acesso	API REST pública (PostgREST) paginada limit/offset (teto 1000/página) + API backend de anexos; 11 programas do MinC filtrados por id_programa
Autenticação	nenhuma — API pública, sem chave
Periodicidade	dinamica (Variable dynamic_schedules; default @daily) nas 4 DAGs de entrada; demais encadeadas por TriggerDagRunOperator
DAGs	api_programas_dag , api_planos_acao_dag , api_plano_acao_meta_dag , api_plano_acao_dado_bancario_dag , api_relatorios_gestao_dag (encadeada) , api_anexos_relatorios_dag (encadeada) , download_anexos_transferegov_dag (encadeada) , api_movimentacoes_financeiras_dag
Destino no data lake	schema transferegov programa_minc , plano_acao_minc , plano_acao_meta_minc , plano_acao_dado_bancario_minc , relatorios_gestao , anexos_relatorios , raw_gestao_financeira_lancamentos , raw_gestao_financeira_subtransacoes Object storage: MinIO/S3 — buckets anexos-lpg, anexos-pnab, anexos-outras (binários das planilhas) e gestao-financeira-fundo-a-fundo (pouso JSON intermediário)
Volumetria	11 programas monitorados; anexos limitados a 3.000/execução no download
Status da integração	Ativa
Consumo no dbt	territorio_fcu_setores e planilhas derivadas alimentam cotas_dbt; plano_acao_minc declarado e usado apenas por modelos desabilitados (cadeia bbágil); plano_acao_meta_minc ainda sem consumo. Endpoints: • GET /programa (api.transferegov.gestao.gov.br/fundoafundo) • GET /plano_acao · /plano_acao_meta · /plano_acao_dado_bancario • GET /relatorio_gestao (filtro FINAL em código) • GET /anexos/relatorio-gestao/{id} e /anexos/rg/{id} (backend, base64) • GET /gestao_financeira_lancamentos · /gestao_financeira_subtransacoes



03 · Relatórios de Gestão PNAB/LPG — planilhas dos entes federados

Campo	Conteúdo
Sistema de origem	Planilhas-modelo (XLSX) preenchidas por estados e municípios e anexadas aos relatórios de gestão finais no TransfereGov
Unidade proprietária	Entes federados (produção) · Ministério da Cultura (modelo e recepção, no âmbito da PNAB e da Lei Paulo Gustavo)
Políticas relacionadas	PNAB (ciclo 1), LPG
Forma de acesso	Download dos anexos via API backend do TransfereGov (base64) para o MinIO, seguido de parsing pandas/calamine por aba e template; roteamento por política; teto de 1.200 colunas por planilha (excedente vai para payload_origem JSON)
Autenticação	nenhuma na origem; MinIO via Airflow Connection · credencial: Connection `minio_default`
Periodicidade	encadeada (api_relatorios → anexos → download → extração)
DAGs	download_anexos_transferegov_dag , extracao_anexos_dag
Destino no data lake	schema relatorio_gestao planilha_editais_lpg , planilha_contemplados_lpg , planilha_dados_lpg , planilha_editais_pnab_ciclo_1 , planilha_contemplados_pnab_ciclo_1 , planilha_dados_pnab_ciclo_1 Chave de upsert: hash_registro = md5(id_anexo indice_subtabela linha_origem)
Volumetria	~10 mil anexos elegíveis; extração em lotes de 50 arquivos
Status da integração	Ativa
Consumo no dbt	É a fonte primária dos domínios cotas_dbt (Meta 3 — cotas) e agentes_dbt (Meta 5 — primeiro acesso): 10 modelos bronze fatiados por tabela_origem.



04 · BB Gestão Ágil — extrato bancário via BSC/SERPRO

Campo	Conteúdo
Sistema de origem	Banco do Brasil — BB Gestão Ágil (contas dos planos de ação), acessado pelo Barramento de Serviços Corporativos do MinC (BSC/SERPRO)
Unidade proprietária	Banco do Brasil (dados bancários) · MinC (autorização de acesso como órgão de controle dos repasses)
Políticas relacionadas	PNAB, LPG — execução financeira na ponta
Forma de acesso	API REST assíncrona (aiohttp), POST por combinação ente×período mensal; sem paginação; semáforo de 5 requisições, throttle 1,05s, retry exponencial; controle de extração idempotente em tabelas próprias
Autenticação	Bearer token via SCA (esquema proprietário: GET com headers clientid/ clientSecret; TTL ~55 min, renovação com lock) · credencial: env vars SCA_CLIENT_ID, SCA_CLIENT_SECRET, SCA_TOKEN_URL
Periodicidade	dinamica (default @daily); janelas mensais de 2023 a 2026
DAGs	extracao_bbagil_dag
Destino no data lake	schema bbagil extrato_bbagil , subtransacao_bbagil , controle_extracao_bbagil_extrato , controle_extracao_bbagil_subtransacoes , fato_bbagil Legados: bb_agil.raw_ingestao_financeira_lancamentos, bsc.raw_bbagil_extrato_transacoes e bsc.raw_bbagil_subtransacoes — pousos de versões anteriores do pipeline, sem produtor ativo; candidatos a arquivamento.
Volumetria	produto entes-com-conta × meses (centenas de milhares de chamadas); execuções longas com bloqueio periódico do BSC (retries=100)
Status da integração	Ativa parcial
Consumo no dbt	Extração ativa, mas a cadeia de transformação (stg_bbagil → bbagil_ente_ano → fct_pagamentos_bbagil → comparativo_recebido_vs_pago) está com enabled=false — aguarda reescrita sobre extrato_bbagil e acesso estável (VPN do governo / SCA).



05 · IBGE — Censo 2022 · Favelas e Comunidades Urbanas (FCU)

Campo	Conteúdo
Sistema de origem	IBGE — CD2022, composição das concentrações urbanas
Unidade proprietária	IBGE
Políticas relacionadas	LPG — 4ª cota (territórios vulnerabilizados), Meta 3
Forma de acesso	CSV pré-processado (fcu_setores_2022.csv) colocado manualmente em data/external/territorio/; leitura local pela DAG
Autenticação	nenhuma — arquivo local
Periodicidade	manual (dado censitário estático; full refresh DROP+CREATE)
DAGs	ingest_territorio_fcu_dag
Destino no data lake	schema transferegov territorio_fcu_setores
Volumetria	33.273 setores censitários → crosswalk setor→FCU→município→UF
Status da integração	Ativa
Consumo no dbt	cotas_dbt.silver.territorio_municipio (grão município, em_concentracao_urbana) → flag_territorio_vulneravel no fato de pagamentos e na distribuição de cotas da LPG.



06 · Cadastros do Sistema Nacional de Cultura (SNC)

Campo	Conteúdo
Sistema de origem	Plataforma do SNC — adesões de entes federados, conselhos, planos e fundos de cultura
Unidade proprietária	Ministério da Cultura — secretaria responsável pela articulação federativa do SNC
Políticas relacionadas	SNC — institucionalização (Eixo 1 do novo PNC)
Forma de acesso	a definir (avaliação entre API, exportação periódica ou dump)
Autenticação	a definir
Periodicidade	a definir
DAGs	— (sem DAG)
Destino no data lake	schema snc (proposto) a modelar (adesões, conselhos, planos, fundos)
Volumetria	n/a
Status da integração	Prevista
Consumo no dbt	n/a — fonte priorizada para a consolidação do SNC (novo PNC, Eixo 1)





O catálogo tem uma única fonte de verdade: o arquivo `docs/fase1-fundamentos/catalogo_fontes_dados.yaml`. A planilha e este PDF são gerados dele por `scripts/fase1_docs/gera_doc1_catalogo_fontes.py` — corrigir a planilha à mão recria a divergência que este documento existe para eliminar.

- Quando atualizar: toda vez que uma DAG de ingestão nascer, mudar de destino/periodicidade ou for desligada; quando um schema novo pousar no banco; quando uma decisão de governança mudar o status de uma fonte.
- Como atualizar: editar o YAML no mesmo pull request da mudança de código e rodar o gerador. O checklist de PR já pede a atualização da documentação do site; este catálogo entra no mesmo hábito.
- Validação: o perfilamento da Fase 1 (`scripts/fase1_docs/perfila_lake.py`) confere se os schemas declarados aqui existem mesmo no banco e alimenta as volumetrias.

