



Critérios de Qualidade dos Dados

As cinco dimensões de qualidade adotadas pela Plataforma de Dados MinC, como cada uma é verificada de forma automatizada, e o inventário completo das verificações hoje em execução.

Universidade de Brasília

Lab Livre · Faculdade do Gama, UnB

Ministério da Cultura

Gov Hub BR

Projeto de Pesquisa

Plataforma de Dados do Ministério da Cultura · Gov Hub BR

Meta 02 · Produto 4

Governança de dados: papéis, acesso e qualidade.

Documento

Critérios de Qualidade dos Dados



Índice

01	Objetivo e escopo	4
02	As cinco dimensões	5
03	Inventário de verificações	6
04	Além dos testes genéricos	8
05	Execução e limites	9





Este documento define os critérios de qualidade dos dados da Plataforma de Dados MinC e demonstra como cada critério é verificado automaticamente a cada execução do pipeline.

Qualidade verificada, não declarada

Um critério de qualidade só é útil quando alguma coisa o verifica sem depender de disciplina humana. Por isso, cada dimensão descrita aqui está associada a um mecanismo de verificação que roda junto com a transformação: se o critério é violado, a execução falha e o problema aparece, em vez de seguir silenciosamente para a camada de consumo.

923verificações
automatizadas**5**

dimensões cobertas

440

tabelas com verificação

2

verificações próprias

As verificações se dividem em dois grupos: 65 sobre os modelos produzidos pela transformação e 858 sobre as tabelas de origem da camada bronze. O segundo grupo é maior porque a camada bronze do SALIC recebe dados de um sistema externo sobre o qual a plataforma não tem controle, e é ali que a integridade precisa ser conferida primeiro.



ONDE AS VERIFICAÇÕES VIVEM

Todas são declaradas nos arquivos `schema.yml` do projeto dbt, ao lado da definição de cada coluna, e executadas pelo comando `dbt test`, orquestrado pela DAG `minc_cosmos_dag`.



A matriz abaixo é o núcleo deste documento: para cada dimensão, o que ela significa na prática, qual mecanismo a verifica e o que acontece quando é violada.

Dimensão	O que garante	Mecanismo
Compleitude	Campos obrigatórios estão preenchidos. Nenhuma chave de junção, classificação ou carimbo de tempo pode ser nulo.	<code>not_null</code>
Unicidade	O grão declarado do modelo é respeitado. Uma tabela de uma linha por documento não pode ter o mesmo documento duas vezes.	<code>unique</code>
Validade	Colunas categóricas só assumem valores do conjunto permitido. Uma raça, um grupo de cota ou um programa fora da lista é erro, não variação.	<code>accepted_values</code>
Consistência	Chaves estrangeiras apontam para registros que existem. Um pagamento não pode referenciar um agente inexistente.	<code>relationships</code>
Atualidade	Toda tabela produzida carrega o momento em que foi calculada, permitindo saber se o número consultado está fresco.	<code>dt_transform</code> no catálogo de metadados



A DIMENSÃO QUE NÃO SE RESOLVE COM TESTE

Atualidade é a única das cinco que não é verificada por um teste de aprovação ou reprovação, e sim por um carimbo consultável. A tabela `metadata.models_metadata` registra `dt_transform` para cada modelo, no fuso America/Sao_Paulo, permitindo que quem consulta descubra sozinho há quanto tempo aquele número não é recalculado.



Distribuição por tipo

Verificação	Dimensão	Modelos	Fontes	Total
not_null	Compleitude	36	552	588
unique	Unicidade	7	257	264
accepted_values	Validade	21	49	70
relationships	Consistência	1	0	1
Total		65	858	923

Cobertura das fontes de origem

Das 709 tabelas declaradas como fonte no projeto, 440 têm ao menos uma verificação. A concentração acompanha o volume: a camada bronze do SALIC responde por praticamente toda a verificação de origem.

Fonte	Verificações
bronze_sac	671
bronze_agentes	97
bronze_tabelas	80
bronze_controledeacesso	8
bronze_bdcorporativo	2



Cobertura dos modelos, por camada

A verificação dos modelos se concentra onde o dado é consumido, e não onde ele pousa. Isso é deliberado: um modelo de bronze existe para receber o que a origem mandou, inclusive o que veio errado; um modelo de gold existe para ser citado.


Camada	Modelos	Colunas descritas	Verificações
agentes · gold	4	23	30
cotas · silver	9	9	14
agentes · bronze	5	15	5
agentes · silver	1	5	4
cotas · gold	6	4	6
metadata	1	7	3
cotas · bronze	9	2	2
agentes · views	1	4	1

As quatro tabelas de gold do domínio de agentes concentram 30 das 65 verificações de modelo, quase metade do total.



LACUNA RECONHECIDA

O gold do domínio de cotas tem 6 verificações para 6 modelos, contra 30 para 4 modelos no domínio de agentes. Quatro dos seis modelos de cotas estão desabilitados por dependerem da extração do BB Ágil, o que explica parte da diferença, mas não toda: `fct_pagamentos_elegiveis` e `cobertura_pagamentos` merecem cobertura equivalente à do outro domínio.



Duas verificações foram escritas para este projeto, em `macros/data_quality/`. Elas cobrem o que os testes genéricos do dbt não alcançam: a integridade de uma carga e a estabilidade do esquema físico.

Conferência de contagem entre origem e destino

A macro `test_row_count_match` compara a contagem de linhas da tabela de origem com a da tabela de destino e falha quando elas divergem. É a verificação de que uma carga não perdeu registros no caminho.

```
with
  source_count as (select count(*) as row_count from {{ source_table }}),
  target_count as (select count(*) as row_count from {{ target_table }}),
  comparison as (
    select source_count.row_count as source_row_count,
           target_count.row_count as target_row_count
    from source_count, target_count
  )
select * from comparison
where source_row_count != target_row_count
```

`macros/data_quality/row_count_match.sql`

Conferência de tipagem

A macro `test_verificacao_tipagem` consulta o `information_schema` do Postgres e falha quando o tipo real de uma coluna difere do tipo esperado. É a proteção contra mudança silenciosa de esquema, que é justamente o risco da ingestão do SALIC, onde todos os valores pousam como texto e a tipagem correta é responsabilidade da transformação.





Quando as verificações rodam

As verificações são executadas pela DAG `minc_cosmos_dag`, que roda o projeto dbt inteiro todo dia à 01h00. O Cosmos transforma cada modelo e cada teste em tarefa própria do Airflow, de forma que uma verificação reprovada aparece como tarefa vermelha na interface, identificando exatamente qual coluna de qual modelo violou qual critério.

Propriedade	Valor
Orquestrador	<code>minc_cosmos_dag</code> (Airflow 3.2 + Cosmos)
Frequência	Diária, 01h00 (<code>0 1 * * *</code>)
Retentativas	2
Granularidade	Uma tarefa do Airflow por modelo e por teste
Recuperação de histórico	Desligada (<code>catchup=False</code>)

Três limites conhecidos

1. **A dimensão de atualidade não tem limiar.** O carimbo `dt_transform` permite descobrir há quanto tempo um modelo não roda, mas não existe alerta configurado para quando esse intervalo ultrapassa um limite aceitável.
2. **A consistência tem uma única verificação.** Apenas `fct_pagamentos_elegiveis` declara `relationships`. Outras junções entre modelos dependem da correção do SQL, sem verificação declarada.
3. **Não há registro histórico de reprovações.** O resultado de cada execução fica nos logs do Airflow, mas não é persistido numa tabela que permita acompanhar a evolução da qualidade ao longo do tempo.





O PRÓXIMO PASSO NATURAL

Os três limites acima se resolvem com o mesmo movimento: persistir o resultado de `dbt test` numa tabela do schema `metadata`, ao lado de `models_metadata`. Isso dá série histórica de qualidade, base para limiar de atualidade e evidência de conformidade sem depender de leitura de log.

O que reprova uma execução hoje

Vale distinguir dois momentos em que a qualidade é verificada, porque eles têm consequências diferentes.

Momento	O que verifica	Reprova?
Execução do pipeline	As 923 verificações de qualidade dos dados, por meio de <code>dbt test</code> .	Sim. A tarefa falha no Airflow.
Integração contínua	Formatação do SQL, por meio de <code>make lint-ci</code> .	Não. A etapa termina com <code> true</code> .

A qualidade *dos dados* tem verificação que reprova; a qualidade *do código* que produz esses dados, hoje, não.

Essa assimetria é a lacuna mais relevante do conjunto: um modelo com erro de lógica que não viole nenhuma das cinco dimensões passa pelas duas verificações sem ser notado. É o que torna a cobertura de teste do código, e não apenas dos dados, parte dos critérios de qualidade.

