



Diagramas de Fluxos de Dados

Os cruzamentos que produzem as camadas silver e gold da Plataforma de Dados MinC: quais modelos alimentam quais, por que chave se juntam e o que cada junção preserva ou descarta.

Universidade de Brasília

Lab Livre · Faculdade do Gama, UnB

Ministério da Cultura

Gov Hub BR

Projeto de Pesquisa

Plataforma de Dados do Ministério da Cultura · Gov Hub BR

Meta 02/03 · Produto 2

Arquitetura e diagramas de fluxos de dados.

Documento

Diagramas de Fluxos de Dados



Índice

01	O que é um fluxo aqui	4
02	O caminho completo	5
03	Os cruzamentos das cotas	6
04	Os cruzamentos dos agentes	9
05	Chaves e cardinalidade	11
06	O ramo desligado	12





Um fluxo de dados, neste documento, é um cruzamento: a operação que pega dois ou mais conjuntos e produz um terceiro. Não é o desenho da infraestrutura por onde o dado trafega, e sim a cadeia de junções, uniões e agregações que transforma pouso bruto em tabela de consumo.

De onde vêm estes diagramas

Nenhum foi desenhado à parte. Cada seta corresponde a uma chamada `ref()` ou `source()` encontrada no SQL dos modelos, e cada rótulo de junção corresponde à cláusula `on` daquele cruzamento. Um modelo novo que ninguém diagramar aparece como lacuna, porque o desenho é derivado da linhagem e não da memória de quem escreveu.

36

modelos na linhagem

6

cruzamentos principais

4

modelos desligados

2

domínios

Como ler os diagramas

fonte declarada bronze silver gold operação desabilitado

As caixas seguem a camada: quanto mais escura, mais perto do consumo. As laranjas não são tabelas, e sim operações (`UNION ALL`, deduplicação, cascata de datação). Os rótulos sobre as setas são a chave de junção.




JUNÇÃO É DECISÃO, NÃO DETALHE

A escolha entre `inner join` e `left join` muda o número publicado. Onde este documento marca `left join`, a decisão foi preservar registros sem correspondência, e cada uma dessas escolhas está anotada no diagrama correspondente.



A plataforma tem dois domínios que partem da mesma origem e não se encontram de novo até a camada de consumo, onde compartilham a chave de agente.



Os dois domínios partem das mesmas planilhas de proponentes e só se separam no bronze:

`cotas_dbt` normaliza documento para casar com pagamento, `agentes_dbt` preserva a resposta bruta sobre histórico de acesso.

Por que a mesma planilha vira dois bronzes diferentes


As planilhas de proponentes alimentam tanto `cotas_dbt` quanto `agentes_dbt`, e cada domínio extrai delas uma coisa distinta. O bronze de cotas normaliza o documento com `normaliza_documento`, porque precisa casar com o pagamento; o bronze de agentes preserva a resposta bruta sobre histórico de acesso a fomento, porque é dela que sai o indicador de primeiro acesso.

Duplicar a leitura da origem é deliberado. A alternativa, um bronze único servindo aos dois, faria cada domínio carregar transformações de que não precisa e acoplaria as duas metas num só modelo.



Três cruzamentos encadeados produzem as tabelas de cota. O primeiro resolve quem é o agente, o segundo resolve quando o pagamento aconteceu, e o terceiro junta os dois lados.

Cruzamento 1: o lado-agente



Cruzamento 1: cinco perfis viram um. A deduplicação é por documento e não por tipo de proponente, e é isso que garante junção um-para-um com os pagamentos mais adiante.




A DEDUPLICAÇÃO DEFINE A CARDINALIDADE DE TUDO O QUE VEM DEPOIS

Uma pessoa pode aparecer como pessoa física num edital e como representante de coletivo em outro. Deduplicar por documento, e não pelo par documento e tipo, é o que reduz o perfil a uma linha por agente e torna a junção com pagamento um-para-um. Sem isso, um pagamento casaria com duas linhas de perfil e o valor seria contado em dobro.



Cruzamento 2: o lado-valor e a data

O ano do edital não vem preenchido em nenhuma das fontes. Ele é derivado em cascata, e a cascata é ela própria um cruzamento: cada tentativa é um `left join` por identificador de anexo.



Fora do intervalo de 2013 a 2026 o ano é descartado; sem ano, a linha vira 'sem_ano'.

Cruzamento 2: a datação em cascata. Cada fonte só é consultada quando a anterior não resolveu, e a coluna `origem_ano` registra qual delas respondeu por cada linha.


Fonte da data	De onde o ano é extraído	Alcance
1. <code>nome_edital</code>	Do próprio nome do edital, quando segue o padrão <code>NN/AAAA</code> .	LPG e PNAB
2. <code>edital_ano_por_anexo</code>	Do campo "número do edital" nas abas de definição do PNAB. Mais completo que o nome.	PNAB
3. <code>edital_ano_por_arquivo</code>	Do nome do arquivo XLSX de origem, que costuma carregar o ano.	LPG e PNAB

A coluna `origem_ano` do resultado guarda qual das três respondeu, o que torna possível medir a confiabilidade da série temporal por fonte de datação.



Cruzamento 3: o fato de pagamentos

É aqui que os dois lados se encontram. O território entra por tabela, não direto: ele se junta ao perfil, porque é o perfil que carrega município e UF do agente.




Cruzamento 3: o fato. As duas junções são **left join** de propósito, para que um pagamento sem perfil demográfico continue no denominador em vez de desaparecer da conta: ele permanece na tabela com **tem_perfil = false**.




POR QUE A COTA TERRITORIAL SÓ EXISTE NA LPG

O diagrama mostra a razão: **territorio_municipio** se junta por **chave_municipio_uf**, que vem do perfil do agente. No PNAB, o lado-valor não traz localização, então essa chave é nula e a quarta cota não é calculável.



O domínio de agentes tem uma topologia diferente: em vez de juntar conjuntos distintos, ele consolida cinco fontes equivalentes e depois deriva classificações sucessivas sobre o mesmo conjunto.



Domínio de agentes. `perfil_agentes_completo` lê as duas pontas, a view de identificadores e a tabela de acesso, para recuperar a resposta bruta ao lado da classificação final. A inferência de primeiro acesso acontece em `perfil_acesso_fomento`, por `row_number()` particionado por documento.

A view `identificadores_agentes` é o ponto de estrangulamento do domínio: tudo passa por ela. Como é materializada como `view`, consolidar os cinco bronzes não custa armazenamento, e qualquer correção num bronze se propaga sem recarga.

As duas classificações e a diferença entre elas

Modelo	Grão	Como classifica
<code>perfil_agentes_historico</code>	agente x programa	Só higieniza e padroniza a resposta declarada. Não infere nada.
<code>perfil_acesso_fomento</code>	agente x programa	Mantém a resposta confirmada e infere as omissas por <code>row_number()</code> sobre o programa.
<code>perfil_agentes_completo</code>	1 linha por agente	Consolida por documento e acrescenta detecção de veteranaria por presença em mais de um programa.



DOIS CAMINHOS PARA O MESMO INDICADOR

`primeiro_acesso_resumo` desce por `perfil_agentes_historico`, que só usa resposta declarada. `primeiro_acesso_contemplados` desce por `perfil_acesso_fomento`, que inclui inferência, e cruza com as listas de contemplados.

Os dois respondem à mesma pergunta por caminhos diferentes, e por isso podem divergir. A divergência não é erro: é a medida do quanto a inferência está pesando no indicador.



Toda junção da plataforma, com a chave usada, o tipo e o efeito da escolha sobre o resultado.

Cruzamento	Chave	Tipo	O que a escolha preserva
<code>perfil_agentes_normalizado</code>	<code>identificador_unico</code>	dedup	Uma linha por documento, com prioridade para pessoa física.
<code>contemplados_unif</code> x anexo	<code>anexo_id</code>	left	A linha sem ano derivável permanece, marcada <code>sem_ano</code> .
<code>fct_*</code> x perfil	<code>identificador_unico</code>	left	O pagamento sem perfil casado permanece, com <code>tem_perfil = false</code> .
<code>fct_*</code> x território	<code>chave_municipio_uf</code>	left	O agente sem município identificado permanece, fora da cota territorial.
<code>perfil_agentes_completo</code>	<code>identificador_unico</code>	distinct on	O primeiro programa de cada agente vira o registro canônico.
<code>identificadores_agentes</code>	sem chave	union all	Todas as linhas dos cinco bronzes, sem deduplicar.

`distinct on` é sintaxe do Postgres: mantém a primeira linha de cada grupo segundo a ordenação declarada.




O PADRÃO POR TRÁS DE TODAS ELAS

Nenhuma junção da plataforma descarta registro por falta de correspondência. A decisão é sempre preservar a linha e sinalizar a ausência numa coluna, para que o denominador continue auditável.

É por isso que existem `tem_perfil`, `origem_ano` e `status_origem`: cada uma delas é a cicatriz de uma junção que não casou.



Um quinto cruzamento está inteiramente escrito e não executa. Ele é o que mediria valor efetivamente pago ao beneficiário final, em vez de valor repassado aos entes.



Bloqueado na origem: a DAG `extracao_bbagil_dag` falha na autenticação SCA.

O ramo que mede valor efetivamente pago está desenhado e desligado. Quatro modelos aguardam a extração do BB Ágil concluir, e devem ser reativados em conjunto.

O que muda quando ele voltar

`comparativo_recebido_vs_pago` existe para confrontar os dois lados-valor: o que `fct_pagamentos_elegiveis` mede hoje, na ordem de R\$ 2,7 bilhões repassados, contra o que `fct_pagamentos_bbagil` mediria, na ordem de R\$ 447 milhões pagos. Enquanto o ramo estiver desligado, esse confronto não acontece e a diferença fica invisível para quem lê as cotas.



REATIVAÇÃO É UMA OPERAÇÃO SÓ

Os quatro modelos devem sair de `enabled=false` em conjunto, depois que `extracao_bbagil_dag` concluir com sucesso. A instrução está registrada na descrição de cada um. Reativar parcialmente quebra a cadeia, porque cada um depende do anterior.